

CGA NLU 使用指南

目标：机器人/对话设计操作员、AI/NLU 专家

本文档选取了 CGA 的 **ML**、**Semantic** 和 **LLM** 引擎，并整理了各引擎的数据、设置、测试和质量改进方法。

1.NLU 基本概念

- 意图：一个分类单元，指示用户的话语正在请求什么。
- 学习句子：注册用于学习意图或用作搜索条件的用户表达。
- 实体：必须从话语中提取的业务值或名称。
- 字典：用于解释领域术语、同义词和用户表达的资产
- 阈值：接受可用结果的最低标准。
- 相似度：指示输入数据和候选数据的含义有多接近的值。
- 答案引擎：选择给定答案或根据分类结果搜索/创建答案的区域

2. 发动机选型标准

类别	机器学习	语义	LLM
基本方法	基于意图和学习句子的分类	嵌入和矢量搜索焦点	LLM 模型和基于指令的处理
准备好数据	意图、学习句子、对象、词典	意图或搜索知识、嵌入·矢量 DB	意图、指令、提供者·模型
一个好的起点	当有可辨别的工作意图和学习句子的管理	当您需要搜索相似的含义时，即使表达方式不同	当需要基于 LLM 的分析/生成和模型运算时
密钥验证	准确性、错误分类、句子平衡	搜索相似度、阈值、索引状态	响应一致性、遵守指示、延迟/成本
主要风险	意图重复、数据不平衡	嵌入兼容性、索引不匹配	模式改变，影响立竿见

			影，反应偏差
--	--	--	--------

根据机器人创建屏幕上的可用选择检查详细模型和支持状态。

3. 常用操作流程

1. 检查机器人和版本。
2. 检查 NLU 方法和模型。
3. 检查答案方法。
4. 准备数据或连接设置。
5. 执行训练、索引创建和模型应用任务。
6. 在模拟器中测试代表性话语。
7. 检查分析/评估/对话历史记录中的结果。
8. 对原因进行分类，更正数据，然后再次测试。

4.质量检验的常用原则

- 一个训练句子包含一个核心意图。
- 相似意图包括可以彼此区分的名词、动词和情境。
- 检查平衡以避免特定意图的数据过载。
- 首先确定域术语是否将作为对象或字典进行管理。
- 测试话语不仅重复与训练句子相同的表达方式。
- 首先改进分析结果中重复错误分类的意图对。

4.2 学习句子的书写规则

注意 将 NLU 指南的原则应用于 CGA 操作数据时，请使用以下顺序：

1. 命名意图以表明任务的目的。
2. 一个训练句子中仅包含一个核心请求。

3. 用不同的词序、语气和表达方式准备相同的意图。
4. 不要只增加与其他意图重叠的单词，包括区分意图的上下文和操作。
5. 不要重复注册相同或几乎相同的句子。
6. 比较每个意图，以确保句子不只集中于特定意图。

例如，当划分 **查询剩余休假天数** 和 **休假申请方法** 时，请准备显示划分标准的表达式，例如 **剩余天数** 和 **申请流程**，而不是在两个意图中都包含单词 **休假**。

4.3 QA/知识数据创建规则

在准备 QA 或基于文档的知识时，请明确问题和答案的范围。

- 问题以实际用户可以输入的表达式编写。
- 答案应直接回答问题，并且不要在一个答案中混合多个主题。
- 对于基于文档的数据，组织原始文本结构以保持标题和正文之间的区别。
- 如果表格或列表很重要，请确保转换后保留其含义。
- 修改文档时，检查申请状态以确保不会同时检索现有文档和新文档。

4.1 运行检查记录

更改引擎设置或训练数据时，记录以下项目。

- 机器人和版本
- NLU 方法、模型、答案方法变更前后
- 更改了意图/对象/字典/QA 或连接设置
- 执行的学习/索引/应用操作和屏幕状态
- 代表成功和失败的话语
- 变更前后的模拟器/分析/评估结果

如果没有此记录，就很难将引擎更改的影响与数据更改的影响分开。

5. 每个引擎的指南

- ML 引擎利用率

- 语义引擎利用
- LLM 引擎利用率

6.利用机器学习引擎

6.1 设置

当前屏幕中识别为 ML 模型的项目是 DeepLearning Lite、TF-IDF Linear 和 Keyword Baseline。实际的学习连接状态与可选择的状态和版本设置一起检查。

6.2 写入数据

- 为每个意图准备代表性表达和各种表达。
- 每个语句仅包含一个意图。
- 需要区分的意图（例如方法和错误查询）不要混合表达式。
- 检查每个意图的句子数量以及表达的多样性。

6.3 测试和改进

1. 分别准备代表性话语和边界话语。
2. 检查模拟器中的结果。
3. 在分析/评估屏幕中查找错误分类意图和重复表达。
4. 修复数据以揭示竞争意图之间的差异。
5. 再次训练并重复相同的测试。

6.4 注意事项

我们并不认为简单地增加训练句子的数量就会自动提高质量。我们不是简单地更改后缀，而是添加了区分意图和与实际用户的各种表达的关键表达式。

更改 ML 之前检查：

1. 用一句话解释一下区分竞争意图的标准。
2. 检查每个意图是否具有代表性表达式、变体表达式或边界表达式。

3. 检查是否存在在一个句子中混合多个意图的学习句子。
4. 重新测试更改后是否保留更改前的成功话语。

7. 利用语义引擎

7.1 类型

- **Semantic - Vector Worker**: 使用 CGA Vector Worker 基本模型和本地矢量 DB 的类型
- **Semantic - External Embedding**: 连接外部嵌入和本地向量 DB 的类型

7.2 设置

当您选择语义 NLU 时，将显示意图向量 DB 连接设置。在外部嵌入类型中，可以使用搜索 API 地址、API Key 选择输入和索引名称。默认的 Vector Worker 类型解析默认的连接和索引名称。

7.3 型号选择

当前代码定义了外部嵌入选项，例如用于韩语一般文档的 **ko-sroberta**，用于多语言、表格和格式的 **multilingual-e5**，以及用于长文档和条款和条件的 **bge-m3**。实际的操作选择是对文档特征、操作连接性和嵌入兼容性的联合检查。

7.4 测试和改进

1. 准备代表性问题和表达。
2. 检查 Vector DB 中是否反映了意图或知识数据。
3. 在模拟器中，相同含义的表达式和不同含义的表达式分别进行测试。
4. 检查搜索结果、相似性、阈值和索引状态。
5. 如果搜索不匹配，请检查数据、嵌入和索引的组合。

实际索引完成状态和搜索结果屏幕必须在浏览器/执行验证后确认。

更改语义之前检查：

1. 验证嵌入模型和正在搜索的数据是否兼容。
2. 验证索引名称和连接目标是否与当前机器人版本匹配。

3. 如果您使用外部搜索 API，请向您的管理员咨询响应规范和身份验证设置。
4. 索引更新之前的结果不会被解释为新数据的质量。

8. 利用 LLM 引擎

8.1 设置

如果选择 LLM Engine，则可以设置 LLM Provider 以及每个 Provider 的详细模型。屏幕上确认的提供商选择包括 Gemini、ChatGPT、Claude、Groq、Cerebras、Mistral、Ollama 和 OpenRouter。例如，如果您选择 ChatGPT，您将看到 **GPT-4o mini (默认)** 和 **GPT-4o (高质量)**。提供商和型号列表可能会根据您的操作设置而有所不同，如果您使用 Ollama，您可能会看到单独的地址条目。

8.2 说明及响应方法

LLM 应该一起审查 NLU 模型选择和答案方法选择。

- LLM Engine 答案：LLM 如何生成答案
- LLM Engine RAG 答案：如何将检索到的知识与 LLM 结合使用
- 定义的答案：如何使用预定义的答案

说明清楚地记录了语气、响应格式和限制。更改指令后，我们将一致性和异常响应与相同的测试集进行比较。

8.3 测试和改进

1. 准备代表性问题、歧义问题以及禁止或例外问题。
2. 修复提供程序和详细模型。
3. 重复相同的输入以检查响应一致性。
4. 验证是否符合指令以及您的回复依据。
5. 记录延迟、成本和失败响应。

LLM 变更前检查：

- 1. 记录更改前后的提供商和详细型号。
- 2. 使用相同的输入/指令/响应方法进行比较。
- 3. 分别检查真实性、格式合规性、禁止响应和失败响应。
- 4. 如果延迟或成本很大，请用质量结果记录它们。

9. 分析与质量改进

分析屏幕检查累积分类结果和应用的步骤。当前屏幕上显示的分类步骤可能包括排除/忽略、闲聊、精确匹配、规则、ML、语义、LLM 等。

质量改进顺序：

- 1. 收集失败的话语。
- 2. 检查实际应用的分类步骤。
- 3. 隔离问题所在的区域：意图、搜索、指令或响应。
- 4. 修复数据的最小范围。
- 5. 一起重新测试现有的成功和失败的话语。

9.1 测试仪配置

更改引擎或修改数据时，不要仅使用一种测试话语。

测试集	目的	标准示例
代表发言	检查正常主要使用路径	常用表达
修改后的话语	检查表达式变化的处理	词序、语气和间距的变化
边界话语	确保与竞争意图区分开	其他类似词语的请求
异常话语	检查不支持/不明确请求的处理	不属于意图的问题
递归话语	变更前确认维护成功结果	先前成功的话语

必须使用更改前后的同一组来比较引擎更改或数据补充的效果。测试结果与机器人、版本、引擎、模型和响应方法一起记录。

10.错误响应

症状	先检查一下	下一步行动
未归类为预期意图	机器人·版本·引擎·数据状态	一起审查代表/边界言论和竞争意图
语义 未找到结果	矢量数据库、索引、嵌入兼容性	检查连接/索引/数据反射状态
LLM 答案动摇	提供者、模型、指令、输入	与相同的测试集进行比较并缩小指令范围
学习或准备状态未完成	学习历史、错误信息、选择组合	记录屏幕状态并与操作人员沟通

验证机器学习机器人中出现的案例：

- 症状：学习请求已注册在队列中，但刷新后仍为 **未训练**
- 模拟器结果：**意图未分类、由于没有训练语句，无法执行意图分类。**
- 判断：训练语句成功保存和 ML 训练完成是不同的状态，因此在训练完成之前不评估分类质量。
- 操作：检查学习历史记录的完成状态，如果没有历史记录，则将机器人、版本、引擎和请求时间发送给运营经理。

不要通过直接修改 DB 或 CLI 来调整状态。记录屏幕上的机器人、版本、引擎、错误信息和发生时间，并传递给运营经理。

11. 学习、索引执行与状态判断

- 执行前确认机器人 UUID、版本、语言、引擎、模型、回答方式、已保存资产和基准测试集。
- ML 学习和 Semantic 索引可能需要三分钟以上。仅出现请求消息不能判定成功。
- 在学习历史中确认最终状态后再运行机器人测试。无历史、仍为未学习、索引为空或 LLM 调用失败都应判定为失败。

12. Score 与 Cut-off 运营

1. 记录当前 Cut-off 和相似度标准。
2. 收集正确、错误、边界和不支持话语的 Score 分布。
3. 每次只修改一个标准，并使用同一回归测试集重新执行。
4. 同时评估误接受和误拒绝，不能只优化画面上的百分比。

13. 多语言 NLU 运营

CGA 的 UI 和机器人语言支持韩语、英语、简体中文、日语、越南语、法语和德语。标识符和 API 契约保持不变，话语、消息、实体和评估集则使用目标语言编写。

消息查询优先使用请求语言，没有时回退到机器人语言。形态、空格、敬语、重音符号和语言特有变体必须分别验证，不能只依赖直译。

14. 受控引擎实验

- 创建独立工作版本，不直接覆盖运营版本。
- 固定测试集，每次实验只修改数据、阈值、模型、Provider、Prompt 或索引设置中的一项。
- 记录准确率、失败类型、回答一致性、延迟、费用和运营限制。
- 只有满足约定标准且保留原成功案例的版本才能切换为运营版本。

15. 质量改进示例

以配送咨询为例，将配送日程与当前状态分开，准备代表、变体、边界、异常和回归话语，确认订单号提取，重新学习或索引，再比较全部测试集。即使错误数减少，如果原成功话语的 Score 下降或意图改变，也不能判定改善成功。

16. 运营反映检查表

- [] 已记录机器人 UUID、版本、语言、引擎、模型和回答方式。
- [] 已用同一测试集比较变更前后结果。
- [] 已在学习历史中确认学习或索引成功。

- [] 已检查 Score、相似意图冲突和回归话语。
- [] 已验证目标语言消息和实体提取。
- [] 已检查实际频道、对话、API 和 Queue 历史。

相关文件

- [查看所有 CGA 手册](#)
- [CGA 入门](#)
- [CGA 用户手册](#)
- [发动机对照表](#)