

# CGA NLU 使用指南

目标：机器人/对话设计操作员、AI/NLU 专家

本文档选取了 CGA 的`ML`、`Semantic`和`LLM`引擎，并整理了各引擎的数据、设置、测试和质量改进方法。

## 1.NLU 基本概念

- 意图：一个分类单元，指示用户的话语正在请求什么。
- 学习句子：注册用于学习意图或用作搜索条件的用户表达。
- 实体：必须从话语中提取的业务值或名称。
- 字典：用于解释领域术语、同义词和用户表达的资产
- 阈值：接受可用结果的最低标准。
- 相似度：指示输入数据和候选数据的含义有多接近的值。
- 答案引擎：选择给定答案或根据分类结果搜索/创建答案的区域

## 2. 发动机选型标准

| 类别     | 机器学习               | 语义                    | LLM                    |
|--------|--------------------|-----------------------|------------------------|
| 基本方法   | 基于意图和学习句子的分类       | 嵌入和矢量搜索焦点             | LLM 模型和基于指令的处理         |
| 准备好数据  | 意图、学习句子、对象、词典      | 意图或搜索知识、嵌入·矢量 DB      | 意图、指令、提供者·模型           |
| 一个好的起点 | 当有可辨别的工作意图和学习句子的管理 | 当您需要搜索相似的含义时，即使表达方式不同 | 当需要基于 LLM 的分析/生成和模型运算时 |
| 密钥验证   | 准确性、错误分类、句子平衡      | 搜索相似度、阈值、索引状态         | 响应一致性、遵守指示、延迟/成本       |
| 主要风险   | 意图重复、数据不平衡         | 嵌入兼容性、索引不匹配           | 模式改变，影响立竿见影，反应偏差       |

根据机器人创建屏幕上的可用选择检查详细模型和支持状态。

### 3. 常用操作流程

1. 检查机器人和版本。
2. 检查 NLU 方法和模型。
3. 检查答案方法。
4. 准备数据或连接设置。
5. 执行训练、索引创建和模型应用任务。
6. 在模拟器中测试代表性话语。
7. 检查分析/评估/对话历史记录中的结果。
8. 对原因进行分类，更正数据，然后再次测试。

### 4. 质量检验的常用原则

- 一个训练句子包含一个核心意图。
- 相似意图包括可以彼此区分的名词、动词和情境。
- 检查平衡以避免特定意图的数据过载。
- 首先确定域术语是否将作为对象或字典进行管理。
- 测试话语不仅重复与训练句子相同的表达方式。
- 首先改进分析结果中重复错误分类的意图对。

#### 4.2 学习句子的书写规则

注意 将 NLU 指南的原则应用于 CGA 操作数据时，请使用以下顺序：

9. 命名意图以表明任务的目的。
10. 一个训练句子中仅包含一个核心请求。
11. 用不同的词序、语气和表达方式准备相同的意图。
12. 不要只增加与其他意图重叠的单词，包括区分意图的上下文和操作。
13. 不要重复注册相同或几乎相同的句子。

14. 比较每个意图，以确保句子不只集中于特定意图。

例如，当划分`查询剩余休假天数`和`休假申请方法`时，请准备显示划分标准的表达式，例如`剩余天数`和`申请流程`，而不是在两个意图中都包含单词`休假`。

### 4.3 QA/知识数据创建规则

在准备 QA 或基于文档的知识时，请明确问题和答案的范围。

- 问题以实际用户可以输入的表达式编写。
- 答案应直接回答问题，并且不要在一个答案中混合多个主题。
- 对于基于文档的数据，组织原始文本结构以保持标题和正文之间的区别。
- 如果表格或列表很重要，请确保转换后保留其含义。
- 修改文档时，检查申请状态以确保不会同时检索现有文档和新文档。

### 4.1 运行检查记录

更改引擎设置或训练数据时，记录以下项目。

- 机器人和版本
- NLU 方法、模型、答案方法变更前后
- 更改了意图/对象/字典/QA 或连接设置
- 执行的学习/索引/应用操作和屏幕状态
- 代表成功和失败的话语
- 变更前后的模拟器/分析/评估结果

如果没有此记录，就很难将引擎更改的影响与数据更改的影响分开。

## 5. 每个引擎的指南

- [ML 引擎利用率](#6 利用机器学习引擎)
- [语义引擎利用](#7 利用语义引擎)
- [LLM 引擎利用率](#8 利用 llm 引擎)

## 6. 利用机器学习引擎

### 6.1 设置

当前屏幕中识别为 ML 模型的项目是 DeepLearning Lite、TF-IDF Linear 和 Keyword Baseline。实际的学习连接状态与可选择的状态和版本设置一起检查。

### 6.2 写入数据

- 为每个意图准备代表性表达和各种表达。
- 每个语句仅包含一个意图。
- 需要区分的意图（例如方法和错误查询）不要混合表达式。
- 检查每个意图的句子数量以及表达的多样性。

### 6.3 测试和改进

15. 分别准备代表性话语和边界话语。
16. 检查模拟器中的结果。
17. 在分析/评估屏幕中查找错误分类意图和重复表达。
18. 修复数据以揭示竞争意图之间的差异。
19. 再次训练并重复相同的测试。

### 6.4 注意事项

我们并不认为简单地增加训练句子的数量就会自动提高质量。我们不是简单地更改后缀，而是添加了区分意图和与实际用户的各种表达的关键表达式。

更改 ML 之前检查：

20. 用一句话解释一下区分竞争意图的标准。
21. 检查每个意图是否具有代表性表达式、变体表达式或边界表达式。
22. 检查是否存在在一个句子中混合多个意图的学习句子。
23. 重新测试更改后是否保留更改前的成功话语。

## 7. 利用语义引擎

### 7.1 类型

- `Semantic - Vector Worker`: 使用 CGA Vector Worker 基本模型和本地矢量 DB 的类型
- `Semantic - External Embedding`: 连接外部嵌入和本地向量 DB 的类型

### 7.2 设置

当您选择语义 NLU 时，将显示意图向量 DB 连接设置。在外部嵌入类型中，可以使用搜索 API 地址、API Key 选择输入和索引名称。默认的 Vector Worker 类型解析默认的连接和索引名称。

### 7.3 型号选择

当前代码定义了外部嵌入选项，例如用于韩语一般文档的 `ko-sroberta`，用于多语言、表格和格式的 `multilingual-e5`，以及用于长文档和条款和条件的 `bge-m3`。实际的操作选择是对文档特征、操作连接性和嵌入兼容性的联合检查。

### 7.4 测试和改进

24. 准备代表性问题和表达。
25. 检查 Vector DB 中是否反映了意图或知识数据。
26. 在模拟器中，相同含义的表达式和不同含义的表达式分别进行测试。
27. 检查搜索结果、相似性、阈值和索引状态。
28. 如果搜索不匹配，请检查数据、嵌入和索引的组合。

*实际索引完成状态和搜索结果屏幕必须在浏览器/执行验证后确认。*

更改语义之前检查：

29. 验证嵌入模型和正在搜索的数据是否兼容。
30. 验证索引名称和连接目标是否与当前机器人版本匹配。
31. 如果您使用外部搜索 API，请向您的管理员咨询响应规范和身份验证设置。
32. 索引更新之前的结果不会被解释为新数据的质量。

## 8. 利用 LLM 引擎

### 8.1 设置

如果选择 LLM Engine，则可以设置 LLM Provider 以及每个 Provider 的详细模型。屏幕上确认的提供商选择包括 Gemini、ChatGPT、Claude、Groq、Cerebras、Mistral、Ollama 和 OpenRouter。例如，如果您选择 ChatGPT，您将看到 `GPT-4o mini（默认）` 和 `GPT-4o（高质量）`。提供商和型号列表可能会根据您的操作设置而有所不同，如果您使用 Ollama，您可能会看到单独的地址条目。

### 8.2 说明及响应方法

LLM 应该一起审查 NLU 模型选择和答案方法选择。

- LLM Engine 答案：LLM 如何生成答案
- LLM Engine RAG 答案：如何将检索到的知识与 LLM 结合使用
- 定义的答案：如何使用预定义的答案

说明清楚地记录了语气、响应格式和限制。更改指令后，我们将一致性和异常响应与相同的测试集进行比较。

### 8.3 测试和改进

33. 准备代表性问题、歧义问题以及禁止或例外问题。

34. 修复提供程序和详细模型。

35. 重复相同的输入以检查响应一致性。

36. 验证是否符合指令以及您的回复依据。

37. 记录延迟、成本和失败响应。

LLM 变更前检查：

38. 记录更改前后的提供商和详细型号。

39. 使用相同的输入/指令/响应方法进行比较。

40. 分别检查真实性、格式合规性、禁止响应和失败响应。

41. 如果延迟或成本很大，请用质量结果记录它们。

9. 分析与质量改进

分析屏幕检查累积分类结果和应用的步骤。当前屏幕上显示的分类步骤可能包括排除/忽略、闲聊、精确匹配、规则、ML、语义、LLM 等。

质量改进顺序：

- 42. 收集失败的话语。
- 43. 检查实际应用的分类步骤。
- 44. 隔离问题所在的区域：意图、搜索、指令或响应。
- 45. 修复数据的最小范围。
- 46. 一起重新测试现有的成功和失败的话语。

9.1 测试仪配置

更改引擎或修改数据时，不要仅使用一种测试话语。

| 测试集    | 目的             | 标准示例        |
|--------|----------------|-------------|
| 代表发言   | 检查正常主要使用路径     | 常用表达        |
| 修改后的话语 | 检查表达式变化的处理     | 词序、语气和间距的变化 |
| 边界话语   | 确保与竞争意图区分开     | 其他类似词语的请求   |
| 异常话语   | 检查不支持/不明确请求的处理 | 不属于意图的问题    |
| 递归话语   | 变更前确认维护成功结果    | 先前成功的话语     |

必须使用更改前后的同一组来比较引擎更改或数据补充的效果。测试结果与机器人、版本、引擎、模型和响应方法一起记录。

10. 错误响应

| 症状       | 先检查一下          | 下一步行动            |
|----------|----------------|------------------|
| 未归类为预期意图 | 机器人·版本·引擎·数据状态 | 一起审查代表/边界言论和竞争意图 |

|            |                |                    |
|------------|----------------|--------------------|
| 语义 未找到结果   | 矢量数据库、索引、嵌入兼容性 | 检查连接/索引/数据反射状态     |
| LLM 答案动摇   | 提供者、模型、指令、输入   | 与相同的测试集进行比较并缩小指令范围 |
| 学习或准备状态未完成 | 学习历史、错误信息、选择组合 | 记录屏幕状态并与操作人员沟通     |

验证机器学习机器人中出现的案例：

- 症状：学习请求已注册在队列中，但刷新后仍为`未训练`
- 模拟器结果：`意图未分类`、`由于没有训练语句，无法执行意图分类。`
- 判断：训练语句成功保存和 ML 训练完成是不同的状态，因此在训练完成之前不评估分类质量。
- 操作：检查学习历史记录地完成状态，如果没有历史记录，则将机器人、版本、引擎和请求时间发送给运营经理。

不要通过直接修改 DB 或 CLI 来调整状态。记录屏幕上的机器人、版本、引擎、错误信息和发生时间，并传递给运营经理。

## 相关文件

- [查看所有 CGA 手册](../README.md)
- [CGA 入门](../cga-getting-started/README.md)
- [CGA 用户手册](../cga-user-manual/README.md)
- [发动机对照表](engine-comparison.md)